Clasificación de sentimientos de reseñas de IMDb con redes neuronales recurrentes, embeddings preentrenados y ensambles

Miguel Muñoz, David Cardenas y Mario Celis

I. Introducción

Clasificar automáticamente la polaridad de reseñas de películas permite resumir la recepción de una obra y alimentar sistemas de recomendación. El problema es difícil porque el sentimiento depende del contexto: negaciones (*not bad at all*), contrastes e ironía (*so bad it's good*) invierten el significado de las palabras aisladas.

Las redes recurrentes con compuertas, LSTM [1] y GRU [2], leen el texto en orden y mantienen un estado que resume el contexto. Necesitan representar las palabras como vectores densos, que Word2Vec [3] y GloVe [4] aprenden sin supervisión. Aun así, en IMDb los modelos lineales de bolsa de bigramas son una línea base muy fuerte [5], [6], porque la polaridad suele expresarse con frases cortas.

El objetivo es clasificar reseñas de IMDb con una RNN y reportar precision, recall y F1 en prueba. A partir de una versión previa (BiGRU con Word2Vec, F1 $= 0{,}9119$), este trabajo: (i) compara Word2Vec entrenado en el dominio con GloVe preentrenado; (ii) evalúa congelar el embedding para controlar el sobreajuste; (iii) ajusta umbral, temperatura y ensambles en validación, y (iv) reporta todo con 3 semillas frente a una línea base TF-IDF.

II. Metodología

Datos. Se usó el conjunto *IMDB Movie Ratings Sentiment Analysis* de Kaggle: 40 000 reseñas en inglés etiquetadas como negativa (0) o positiva (1), con clases balanceadas. Se eliminó el HTML, se pasó a minúsculas y se tokenizó conservando contracciones (*didn't*) y los signos `!/?`, sin quitar *stopwords*, porque *not* o *but* deciden la polaridad. Para evitar fuga de datos se eliminaron 280 duplicados antes de partir. La partición es estratificada 70/15/15: 27 804 / 5 958 / 5 958 reseñas. El vocabulario (20 002 términos con frecuencia ≥ 2) se construye solo con entrenamiento. Cada reseña se trunca a 200 tokens ($\frac{1}{4}$ inicial y $\frac{3}{4}$ finales), lo que deja completo el 58 % de las de entrenamiento.

Embeddings (dimensión 100). Se compararon dos: Word2Vec *skip-gram* [3] (ventana 5), entrenado solo con entrenamiento, y GloVe 6B [4] (Wikipedia + Gigaword). En GloVe, cada contracción recibe el promedio de sus partes (*did*, *n't*), lo que sube su cobertura del 96,6 % al 99,6 %.

Arquitectura. Embedding $20\,002 \times 100$ (entrenable o congelado) $\rightarrow$ dropout 0,3 [7] $\rightarrow$ GRU bidireccional [8] de 1 capa con 64 unidades por dirección $\rightarrow$ promedio y máximo de las salidas (256) $\rightarrow$ dropout 0,3 $\rightarrow$ capa densa con sigmoide, que da $P(\text{positiva})$. Las compuertas mitigan el desvanecimiento del gradiente [9], y el máximo retiene expresiones fuertes aunque aparezcan a mitad del texto. Fue la mejor en validación en la versión previa. Tiene 2,06 M de parámetros, el 97 % en el embedding; al congelarlo quedan 64 k entrenables.

TABLA I
Resultados en prueba (5 958 reseñas); (3s): media ± desv. est. de 3 semillas. 200 tokens salvo v1.

Modelo	Acc.	P	R	F1	AUC
TF-IDF + reg. logística	0,918	0,916	0,921	0,9187	0,972
v1: BiGRU W2V, 400 tok. (3s)	0,911	0,902	0,923	0,9119±0,0034	0,969
BiGRU Word2Vec (3s)	0,902	0,889	0,920	0,9044±0,0010	0,963
BiGRU GloVe (3s)	0,903	0,895	0,913	0,9040±0,0028	0,964
BiGRU GloVe congelado (3s)	0,889	0,879	0,904	0,8907±0,0014	0,958
GloVe + umbral (3s)	0,903	0,895	0,914	0,9044±0,0029	0,964
GloVe, ens. 3 sem. + umbral	0,903	0,889	0,922	0,9054	0,965
GloVe + TF-IDF + umbral (3s)	0,921	0,916	0,927	0,9213±0,0015	0,974
Ens. 3 sem. + TF-IDF + umbral	**0,923**	**0,920**	**0,927**	**0,9231**	**0,974**

Entrenamiento. Entropía cruzada binaria con Adam [10] (tasa de aprendizaje 10^{-3}, lotes de 128) y *clipping* de norma 1 [11]. La tasa se reduce a la mitad si la F1 de validación se estanca. Máximo 10 épocas con *early stopping* (paciencia 3) sobre la F1 de validación. Semillas 42, 7 y 123.

Postproceso. Con las predicciones de *validación* se eligen: el umbral que maximiza la F1; la temperatura T que minimiza la *log-loss* [12]; el promedio de semillas, y el peso w de $w\,P_{\text{RNN}} + (1-w)\,P_{\text{TF-IDF}}$. La línea base es TF-IDF de 1-2 gramas sobre la reseña completa con regresión logística [6]. El conjunto de prueba solo se usa para reportar.

Métricas. Precision, recall y F1 de la clase positiva (las que pide el enunciado; balancean falsos positivos y negativos), accuracy, ROC-AUC (independiente del umbral) y el error de calibración esperado (ECE). Se calcula un IC 95 % por *bootstrap* (1 000 remuestreos). El código está en `01_solucion_rnn_imdb_2.ipynb`.

III. Resultados

Cuantitativos. La Tabla I resume los resultados en prueba. Word2Vec y GloVe empatan ($0{,}9044 \pm 0{,}0010$ frente a $0{,}9040 \pm 0{,}0028$). Se eligió GloVe por su mayor F1 de validación ($0{,}9057$ frente a $0{,}9036$). Congelar el embedding baja la F1 a $0{,}8907$. El congelado mejora lentamente hasta la época 10 (Fig. 1a), mientras el entrenable sobreajusta desde la época 3: su pérdida de validación sube y la de entrenamiento cae (Fig. 1b).

El umbral ajustado (entre 0,47 y 0,53) cambia la F1 en solo $+0{,}0004$. La temperatura ($T = 1{,}14$ a $1{,}35$) baja el ECE de 0,024 a 0,009 sin cambiar las predicciones (Fig. 1c). Ensamblar con TF-IDF ($w = 0{,}4$ a $0{,}5$) y umbral ajustado

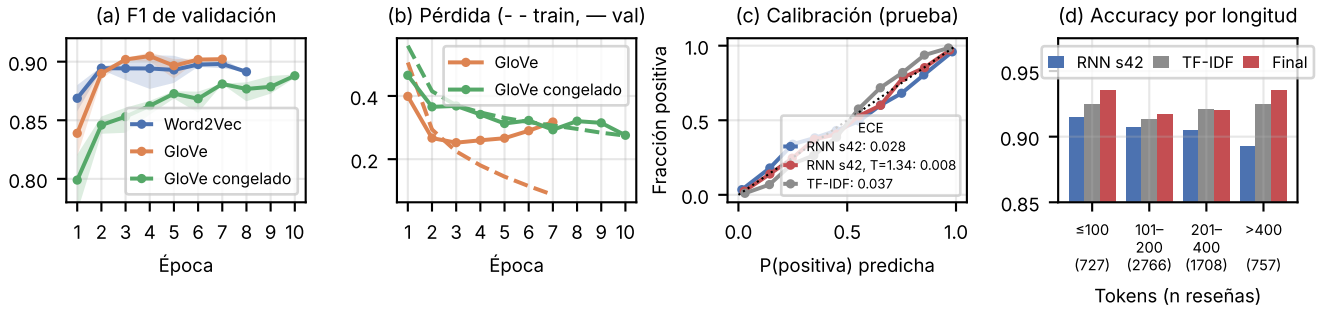


Fig. 1. (a) F1 de validación por época (media y rango de 3 semillas). (b) Pérdida media de entrenamiento (discontinua) y validación (continua), GloVe entrenable y congelado. (c) Diagrama de confiabilidad en prueba de la RNN (semilla 42) antes y después de la calibración, y de TF-IDF. (d) Accuracy en prueba por longitud de la reseña.

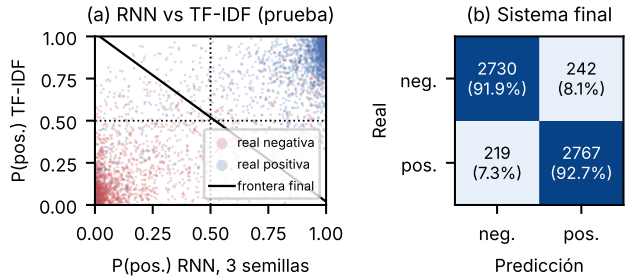


Fig. 2. (a) $P(\text{positiva})$ del ensamble de 3 semillas de la RNN frente a TF-IDF en prueba, coloreada por la etiqueta real. Las líneas punteadas son el umbral 0,5 de cada modelo y la continua es la frontera del sistema final. (b) Matriz de confusión del sistema final.

TABLA II

EJEMPLOS DE PRUEBA: ETIQUETA REAL Y $P(\text{POSITIVA})$ DE LA RNN (SEMILLA 42), DE TF-IDF Y DEL SISTEMA FINAL.

Reseña (inicio)	**Real**	**RNN**	**TF-IDF**	**Final**
certainly one of the finest movies...	+	1,00	1,00	1,00
this is the worst movie i have ever...	−	0,00	0,00	0,00
this movie was pure genius john waters...	−	1,00	1,00	1,00
...makes a bad movie worth watching...	+	0,00	0,00	0,00
far too few mainstream films... (690 tok.)	+	0,19	0,93	0,65
as a big fan of the original film...	−	0,91	0,05	0,45

sube la F1 a $0{,}9213 \pm 0{,}0015$. El sistema final, elegido por F1 de validación, combina el promedio de 3 semillas con TF-IDF: obtiene F1 $= 0{,}9231$ (IC 95 %: 0,9160 a 0,9299), con 242 falsos positivos y 219 falsos negativos (Fig. 2b). Frente a la línea base la diferencia es $+0{,}0044$, con IC 95 % de $-0{,}0012$ a $+0{,}0100$. En las reseñas de más de 400 tokens, la RNN sola acierta 0,893, TF-IDF 0,925 y el sistema final 0,935 (Fig. 1d).

Cualitativos. La Tabla II muestra reseñas de prueba con su etiqueta real y la probabilidad de cada modelo. En la Fig. 2a, la RNN y TF-IDF discrepan en 469 reseñas (7,9 %), justo la zona que resuelve la frontera del ensamble. Frente a la RNN (semilla 42), el sistema final corrige 157 errores, introduce 55 y baja los errores con confianza $> 0{,}9$ de 177 a 54.

IV. DISCUSIÓN

Embeddings. Inicializar con vectores preentrenados importa más que su fuente. En la versión previa, pasar de embeddings aleatorios a Word2Vec sumó entre 2 y 3 puntos de F1; aquí GloVe y Word2Vec empatan. Al ser entrenable, el embedding (2 M parámetros) se adapta a la tarea y borra la diferencia de partida: GloVe empieza peor y alcanza a Word2Vec en la época 3 (Fig. 1a). Además, GloVe codifica co-ocurrencia general y no polaridad (entre los vecinos de *boring* está *funny*), una limitación ya descrita para el análisis de sentimiento [5].

Capacidad y sesgo-varianza. Con 2 M de parámetros y 28 k reseñas, el modelo entrenable memoriza desde la época 3, y es el *early stopping* el que controla su varianza (brecha de accuracy entre entrenamiento y validación de 0,020). Congelar el embedding cambia varianza por sesgo: la brecha cae a $-0{,}003$, pero el modelo subajusta (1,3 puntos menos de F1), porque 64 k parámetros no bastan para separar palabras que GloVe deja cerca pese a tener polaridad opuesta.

Calibración. $T > 1$ en todas las semillas indica que la red es sobreconfiada, algo típico de redes entrenadas con entropía cruzada [12]. El umbral óptimo quedó cerca de 0,5 porque los errores ya están equilibrados, a diferencia de la versión previa (375 falsos positivos frente a 175 falsos negativos).

Complementariedad. El ensamble con TF-IDF es la mejora principal (+1,7 puntos sobre la RNN), porque los errores de los dos modelos están poco correlacionados: la RNN modela el orden pero lee solo 200 tokens, mientras TF-IDF ve la reseña completa sin orden [6]. Así se corrigen la reseña larga y la crítica del *remake* de la Tabla II. La mejora frente a TF-IDF no es significativa, porque su IC incluye el cero. La RNN sola (F1 de 0,904 con 200 tokens y 0,912 con 400 en la v1) cumple por sí sola el enunciado; el ensamble es una mejora adicional.

Limitaciones y mejoras. Los errores más confiados, compartidos por todos los modelos, son ruido de etiquetado probable (*pure genius* etiquetada como negativa) e ironía; fijan un techo al desempeño. Se proponen: (i) GloVe con 400 tokens más el ensamble; (ii) descongelar el embedding gradualmente, y (iii) leer las reseñas largas por segmentos o con atención.

REFERENCIAS

[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Comput.*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho *et al.*, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proc. EMNLP*, 2014, pp. 1724–1734.

[3] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," arXiv:1301.3781, 2013.

[4] J. Pennington, R. Socher, and C. D. Manning, "GloVe: Global vectors for word representation," in *Proc. EMNLP*, 2014, pp. 1532–1543.

[5] A. L. Maas, R. E. Daly, P. T. Pham, D. Huang, A. Y. Ng, and C. Potts, "Learning word vectors for sentiment analysis," in *Proc. ACL-HLT*, 2011, pp. 142–150.

[6] S. Wang and C. D. Manning, "Baselines and bigrams: Simple, good sentiment and topic classification," in *Proc. ACL*, 2012, pp. 90–94.

[7] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *J. Mach. Learn. Res.*, vol. 15, pp. 1929–1958, 2014.

[8] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Trans. Signal Process.*, vol. 45, no. 11, pp. 2673–2681, 1997.

[9] Y. Bengio, P. Simard, and P. Frasconi, "Learning long-term dependencies with gradient descent is difficult," *IEEE Trans. Neural Netw.*, vol. 5, no. 2, pp. 157–166, 1994.

[10] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. ICLR*, 2015.

[11] R. Pascanu, T. Mikolov, and Y. Bengio, "On the difficulty of training recurrent neural networks," in *Proc. ICML*, 2013, pp. 1310–1318.

[12] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. ICML*, 2017, pp. 1321–1330.